NOTA DE DECISIÓN METODOLÓGICA | NOTICIAS EODHD

Exclusión de customer_concentration

Evidencia, alcance y condiciones para excluir provisionalmente esta familia del dataset principal de noticias.

DECISIÓN	**Excluir `customer_concentration` como clase objetivo del dataset principal de noticias EODHD. Mantener `cybersecurity` y `critical_suppliers`.**

ALCANCE	La exclusión afecta solo al experimento de noticias. La familia sigue siendo válida en la taxonomía y en el análisis de los 10-K. Reglas, candidatos y evidencias históricas se conservan para trazabilidad y exploración.

13 / 13	0	1 / 5
asignaciones de familia incorrectas en desarrollo	episodios independientes elegibles en el benchmark	familia confirmada en la muestra amplia de 2026

Evidencia del filtro de desarrollo

Las 13 asignaciones de familia observadas fueron incorrectas. Las activaciones por término pueden solaparse y la precisión siguiente mide selección de noticias de riesgo; no confirma por sí sola que la familia propuesta fuera correcta.

Término	Activaciones	Falsos positivos	Precisión observada
major customer	8	7	12,5 %
key customer	4	4	0,0 %
customer concentration	2	2	0,0 %

Evidencia de cobertura

El inventario auditado no contiene episodios independientes y elegibles de customer_concentration. En la adquisición amplia de enero-septiembre de 2026 se examinaron 9.861 relaciones artículo-empresa y se obtuvieron 57 candidatos.

Familia	Candidatos léxicos
cybersecurity	36
critical_suppliers	16
customer_concentration	5

Los cinco candidatos de customer_concentration equivalen a aproximadamente el 0,05 % del universo admitido. La revisión humana confirmó uno en esa familia; otro pertenecía a critical_suppliers y tres fueron falsos positivos. Precisión de familia observada: **1/5 (20,0 %)**.

Fuentes auditables

- `reports/eodhd_risk_news_development.md`
- `reports/eodhd_reference_filter_report.md`
- `reports/eodhd_known_episode_recovery.md`
- `data/processed/eodhd_mag7/datasets/mag7-risk-train-2026-bf1/dataset_manifest.json`
- `data/processed/eodhd_mag7/datasets/mag7-risk-train-2026-bf1/risk_news_candidates_review.csv`

JUSTIFICACIÓN Y REAPERTURA

Por qué no es una clase entrenable hoy

La concentración de clientes suele ser una exposición estructural, no un acontecimiento noticioso puntual. Los 10-K, cuentas anuales y publicaciones financieras específicas son fuentes más naturales para observarla.

Tres riesgos metodológicos

1	**Clase extremadamente minoritaria** Cinco candidatos entre 9.861 relaciones (aprox. 0,05 %): volumen insuficiente para entrenamiento, validación y test separados.
2	**Evidencia positiva insuficiente** Solo un caso confirmado en 2026; ninguno en el corpus de desarrollo y ningún episodio independiente para medir recuperación.
3	**Riesgo de aprender ruido** Los términos major customer y key customer activan relaciones comerciales o menciones que no demuestran concentración de clientes.

VOLUMEN	La exclusión no resuelve el problema general de escala: el paquete pasa de 57 a 52 candidatos. Aún es necesario revisar la precisión y mejorar la recuperación de cybersecurity y critical_suppliers antes de considerar alcanzable el tamaño objetivo.

Condiciones para reconsiderar la decisión

La reapertura solo puede apoyarse en evidencia nueva obtenida sobre entrenamiento, sin utilizar validación ni test para ajustar reglas.

1	**Búsqueda dirigida**	Definir antes una estrategia adecuada para exposiciones estructurales, no solo noticias episódicas.
2	**Muestra humana suficiente**	Obtener positivos confirmados que permitan partición y evaluación separadas.
3	**Validez demostrable**	Probar precisión y relevancia empresarial, no solo coincidencias léxicas.
4	**Reglas congeladas**	Ajustar únicamente con entrenamiento y congelar las reglas antes de consultar validación o test.

CONDICIÓN VIGENTE	Hasta cumplir las cuatro condiciones, los cinco candidatos existentes se mantienen como material exploratorio, no como ejemplos de una clase entrenable.