NOTA TÉCNICA | PIPELINE DE NOTICIAS EODHD

Cómo funciona el filtro léxico de riesgo

De una noticia normalizada a una relación noticia-empresa candidata para cybersecurity o critical_suppliers.

FUNCIÓN	**Recuperar candidatos de alta cobertura y explicar por qué se seleccionaron. No es un clasificador final ni genera etiquetas *gold*.**

0	±180	2
modelos entrenados o llamadas a un LLM	caracteres de contexto alrededor de la empresa	familias objetivo del dataset principal

Pipeline de selección

1	**Normalizar texto** Une título y cuerpo; convierte a minúsculas, sustituye puntuación por espacios y colapsa blancos.	`title + content -> normalized_text`
2	**Acotar a la empresa** Busca alias configurados (p. ej., Microsoft, Windows o Azure) y conserva ventanas de ±180 caracteres. Sin alias, no hay evidencia.	`company_alias_patterns`
3	**Activar familias** Aplica expresiones regulares etiquetadas. Una noticia puede activar varias familias y varios términos a la vez.	`risk_rules[family]`
4	**Exigir adversidad** Descarta todas las coincidencias si el contexto no contiene un patrón de ataque, fallo, interrupción, pérdida u otro daño.	`adverse_event_patterns`
5	**Suprimir y registrar** Resuelve ambigüedades conocidas y guarda familias candidatas y etiquetas activadoras para auditoría.	`risk_family_candidates + risk_match_terms`

Ejemplo de una ambigüedad resuelta

Etapa	Resultado para el ejemplo Microsoft
Texto	“Global IT outage affects Microsoft Windows. A faulty update caused the outage; it was not a cyberattack.”
Coincidencias	critical_suppliers: technology outage + software update failure; cybersecurity: cyberattack.
Supresión	La negación y el vínculo update/outage eliminan cybersecurity cuando critical_suppliers también está presente.
Salida	critical_suppliers, conservando los términos que justifican la selección.

LÍMITE CLAVE	El filtro reconoce patrones, no significado completo. Puede confundir otra empresa, publicidad, regulación o una mención hipotética. La revisión humana decide relevancia, corrige la familia, asigna el estado del riesgo y documenta el ruido. Sus activaciones son candidatos, no verdad de terreno.

Fuentes: src/news/risk_filter.py · src/news/normalize.py · config/eodhd_pilot.json · src/tests/test_news_risk_filter.py