NOTA METODOLÓGICA | DATASET DE NOTICIAS DE RIESGO

Adquirir noticias fuera; construir las etiquetas dentro

Por qué el análisis MAG7 2021-2026 necesita un dataset propio con revisión humana, en lugar de adoptar sin más un corpus encontrado en internet.

DECISIÓN	**Usar fuentes externas para adquirir noticias, pero construir internamente las etiquetas de evaluación mediante revisión humana.**

1	2	40 x 3
unidad: relación noticia-empresa	familias objetivo definidas operacionalmente	casos comunes para calibración independiente

La brecha metodológica

Criterio	Dataset externo sin adaptar	Dataset propio revisado
Alineación	Suele responder a otra tarea: tema, sentimiento, entidad o evento genérico.	Etiqueta exactamente riesgo relevante, familia y estado del acontecimiento.
Unidad	Artículo o evento; puede perder qué empresa está realmente afectada.	Relación noticia-empresa: una noticia puede ser positiva para una empresa y ruido para otra.
Ámbito	Empresas, periodo y taxonomía fijados por terceros.	MAG7, 2021-2026 y familias *cybersecurity* y *critical_suppliers*.
Calidad	Criterios, duplicados, procedencia o cambios de etiqueta pueden ser opacos.	Guía explícita, hashes, grupos de duplicados y trazabilidad hasta la fuente.
Validez	Una etiqueta disponible no equivale automáticamente a un *gold standard* para esta pregunta.	Calibración independiente, comparación de desacuerdos y adjudicación por consenso.

21 / 57 candidatos léxicos de la muestra de 2026 fueron noticias de riesgo positivas tras la revisión humana. Los otros 36 (63,2%) eran ruido: una coincidencia léxica no constituye una etiqueta válida. **Métrica de desarrollo; no estima recall.**

Qué aporta la revisión humana

CONTEXTO EMPRESARIAL
Distingue una empresa realmente afectada de una mención, un competidor o una relación comercial invertida.

SEMÁNTICA DEL RIESGO
Confirma familia y separa impacto materializado, exposición vigente y amenaza emergente.

CONTROL DE ETIQUETAS
Hace visibles los desacuerdos, documenta el consenso y diferencia etiquetas *gold* de *silver*.

QUÉ SÍ REUTILIZAR

Los datasets públicos siguen siendo útiles como fuente de noticias, vocabulario, comparación o preentrenamiento. Deben incorporarse si superan controles de licencia, cobertura, deduplicación y mapeo de etiquetas; no como sustituto automático de la validación humana específica del proyecto.

ESTADO ACTUAL

La calibración de los tres anotadores sigue en curso. Hasta comparar desacuerdos y resolverlos por consenso, las etiquetas no deben presentarse como *gold standard* ni como estimación final de rendimiento.

Fuentes internas: `reports/risk_news_annotation_guide.md` · `reports/eodhd_risk_news_development.md` · `config/eodhd_dataset_2021_2026.json`